



МОСКОВСКИЙ
ГОСУДАРСТВЕННЫЙ
УНИВЕРСИТЕТ
имени М. В. Ломоносова



Факультет вычислительной математики и кибернетики

Учебный курс
«ТЕХНОЛОГИЧЕСКИЙ ПРАКТИКУМ»

Отчёт
о выполненном задании

студентки 316 учебной группы факультета ВМК МГУ
Вагаповой Деши Насрудиновны

Москва
2025

Contents

1	Описание датасета, краткие характеристики (максимумы, минимумы, средние значения, пропуски и т.п.)	4
1.1	Структура и признаки датасета	4
1.2	Краткие статистические характеристики	4
1.3	Пропуски в данных	5
2	Аппроксимация распределений данных с помощью ядерных оценок плотности (KDE)	6
2.1	KDE по признаку <code>danceability</code>	6
2.2	KDE по признаку <code>energy</code>	6
2.3	KDE по признаку <code>loudness</code>	7
2.4	KDE по признаку <code>tempo</code>	7
2.5	KDE по остальным признакам	8
2.6	Общие выводы по KDE-графикам	9
3	Анализ данных с помощью <code>boxplot</code>, <code>stripchart</code>, <code>dotchart</code> и <code>cdplot</code>	10
3.1	Boxplot для числовых признаков	10
3.2	Stripchart для числовых признаков	11
3.3	Нормализованные boxplot (z-score)	12
3.4	Dotchart: сравнение танцевальности по поджанрам	12
3.5	CD-plot аналог: распределение популярности по поджанрам	13
3.6	Общий итог по разделу	13
3.7	Сравнение результатов с реализацией на языке R	14
3.7.1	Boxplot и stripchart в R	14
3.7.2	Нормализованные boxplot (z-score) в R	15
3.7.3	Dotchart и CD-plot в R	15
3.7.4	Общий вывод о сравнении Python и R	16
4	Выявление выбросов с точки зрения формальных критериев Граббса и Q-теста Диксона	17
4.1	Проверка нормальности для <code>tempo</code> и <code>loudness</code> (Python)	17
4.1.1	Признак <code>tempo</code>	18
4.1.2	Признак <code>loudness</code>	19
4.2	Проверка нормальности и выбросов в R	20
4.2.1	QQ-графики с огибающими (R)	20
4.2.2	Граббс на реальных данных (R)	20
4.3	Критерий Граббса	21
4.4	Q-тест Диксона	21
4.5	Демонстрация корректной работы тестов на синтетической нормали	21
4.5.1	Результаты Python	22
4.5.2	Результаты R	22
4.6	Итоговые выводы по главе	23
5	Заполнение пропусков: сравнение методов <code>mean</code>, <code>kNN</code> и <code>MICE</code>	24
5.1	Распределение признака до и после внесения пропусков	24
5.2	Сравнение методов импутации на Python	25
5.3	Сравнение истинных и восстановленных значений	25
5.4	Сравнение методов импутации на языке R	25
5.5	Сравнение Python и R	26
5.6	Общие выводы	26

6	Проверка нормальности: тесты, Q–Q графики с огибающей и гистограммы	28
6.1	Синтетические нормальные выборки	28
6.1.1	Результаты на Python	29
6.1.2	Результаты на R и сравнение с Python	29
6.2	Нормальность реальных признаков Spotify Songs	30
6.2.1	Python: Q–Q графики и гистограммы	30
6.2.2	Python: формальные тесты нормальности	30
6.2.3	R: графики и сравнение	31
6.3	Общий вывод по разделу	31
7	Одновыборочный критерий Стьюдента	31
7.1	Двухвыборочный критерий Стьюдента для двух независимых выборок	34
7.2	Критерий Уилкоксона–Манна–Уитни	42
7.3	Пояснения к критерию Манна–Уитни и тестам на равенство дисперсий	42
7.4	Проверка нормальности распределений популярности	44
7.5	Проверка гипотез об однородности дисперсий	45
8	Корреляционный анализ	46
8.1	Коэффициент корреляции Пирсона	47
8.2	Коэффициент корреляции Спирмена	49
8.3	Коэффициент корреляции Кендалла	49
8.4	Сводные выводы по корреляционному анализу	50
9	Тесты для категориальных данных: χ^2, точный тест Фишера, критерий Кохрана–Мантеля–Хензеля (СМН)	52
9.1	1. Таблицы сопряженности	52
9.2	2. Критерий χ^2 для независимости	52
9.3	3. Точный тест Фишера (таблица 2×2)	53
9.4	4. Критерий Кохрана–Мантеля–Хензеля (СМН)	53
9.5	5. Тест МакНемара	53
9.6	6. Визуализация категориальных зависимостей	53
9.7	7. Общий вывод по разделу	54
10	Проверка мультиколлинеарности	55
10.1	Корреляционная матрица	55
10.2	Фактор инфляции дисперсии (VIF)	56
10.3	Выводы	57
11	Дисперсионный анализ (ANOVA)	58
11.1	Предварительная проверка предположений ANOVA	58
11.2	Однофакторный ANOVA	58
11.3	Двухфакторный ANOVA	59
11.4	Выводы	61
12	Регрессионный анализ	61
13	Регрессионный анализ	61
13.1	1. Линейная регрессия (baseline)	61
13.2	2. Попытка убрать мультиколлинеарность (VIF)	62
13.3	3. Полиномиальная регрессия	64
13.4	4. Причины низкого качества моделей	66
13.5	Итоговые выводы	66

1 Описание датасета, краткие характеристики (максимумы, минимумы, средние значения, пропуски и т.п.)

В качестве датасета для выполнения задания был выбран набор данных `spotify_songs.csv`, содержащий информацию об аудиопризнаках и метаданных треков Spotify. После загрузки данных получена таблица размера 18454×25 , то есть 18454 трека и 25 признаков.

1.1 Структура и признаки датасета

Все признаки можно разделить на несколько смысловых блоков:

1. Идентификаторы и текстовые поля:

- `track_id` — уникальный идентификатор трека;
- `track_name` — название трека;
- `track_artist` — исполнитель;
- `lyrics` — текст песни.

2. Информация об альбоме:

- `track_album_id` — идентификатор альбома;
- `track_album_name` — название альбома;
- `track_album_release_date` — дата релиза.

3. Информация о плейлисте:

- `playlist_name` — название плейлиста;
- `playlist_id` — идентификатор плейлиста;
- `playlist_genre` — жанр плейлиста;
- `playlist_subgenre` — поджанр.

4. Числовые аудиопризнаки:

- `danceability`, `energy`, `loudness`, `speechiness`, `acousticness`, `instrumentalness`, `liveness`, `valence`, `tempo`, `duration_ms`, `track_popularity`.

5. Категориальные признаки:

- `mode` — лад (0 — минор, 1 — мажор);
- `key` — тональность (0–11);
- `language` — язык трека.

1.2 Краткие статистические характеристики

Для числовых признаков были посчитаны стандартные описательные статистики: число наблюдений, среднее, стандартное отклонение, минимальные и максимальные значения, а также квартили. Результаты сведены в таблицу 1.

Table 1: Статистические характеристики числовых признаков

Параметр	Count	Mean	Std	Min	25%	50%	75%	Max
danceability	18454	0.64	0.15	0.098	0.546	0.660	0.755	0.979
energy	18454	0.69	0.18	0.017	0.573	0.715	0.835	1.000
loudness	18454	-6.77	2.92	-34.28	-8.25	-6.23	-4.72	1.28
tempo	18454	120.8	27.6	37.11	98.85	120.04	135.98	214.05
duration_ms	18454	230319	57255	31893	193230	221340	258078	517810
track_popularity	18454	42.4	24.6	0	24	48	62	100




Figure 1: Доля пропусков по столбцам датасета

1.3 Пропуски в данных

Анализ пропусков показал, что среди основных числовых признаков пропусков нет. Небольшая доля пропусков присутствует только в столбцах `lyrics` и `language` (около 1.4% в каждом), что отражено на диаграмме 1.

Таким образом, числовые данные полные и пригодны для дальнейшего статистического анализа, а пропуски локализованы в текстовых полях.

2 Аппроксимация распределений данных с помощью ядерных оценок плотности (KDE)

Ядерная оценка плотности (Kernel Density Estimation, KDE) — это метод восстановления неизвестной функции плотности распределения случайной величины на основе выборки. KDE позволяет сгладить распределение, избежать шумов гистограммы и получить непрерывную кривую плотности. Метод активно применяется для первичного анализа данных, определения формы распределения, выявления асимметрии, мультимодальности и наличия хвостов.

В рамках исследования для всех числовых признаков датасета были построены KDE-графики: `danceability`, `energy`, `loudness`, `speechiness`, `acousticness`, `instrumentalness`, `liveness`, `valence`, `tempo`, `duration_ms`, `track_popularity`. Графики были сгенерированы на Python и сохранены программно в директорию `картинки/`.

2.1 KDE по признаку `danceability`




Figure 2: KDE для признака `danceability`

Выводы:

1. Распределение одновершинное и близко к нормальному, но слегка смещено вправо (большинство треков имеют среднюю–высокую танцевальность).
2. Хвосты короткие, ярко выраженных выбросов нет.
3. Значения концентрируются в диапазоне 0.55–0.75, что является типичным для популярной музыки.

2.2 KDE по признаку `energy`

Выводы:

1. Функция плотности симметричная, с пиком около 0.7.
2. Большинство треков имеют высокую энергичность, что характерно для современных жанров.




Figure 3: KDE для признака `energy`

3. Левый хвост немного длиннее правого, что говорит о небольшом перекосе в сторону низких значений.

2.3 KDE по признаку `loudness`




Figure 4: KDE для признака `loudness`

Выводы:

1. Распределение асимметрично и вытянуто влево.
2. Признак не является нормальным: присутствуют длинные хвосты.
3. Это объясняется тем, что громкость зависит от жанра и типа записи.

2.4 KDE по признаку `tempo`

Выводы:




Figure 5: KDE для признака `tempo`

1. Распределение имеет две выраженные моды: около 100 и 120 BPM.
2. Это связано с тем, что большинство популярных треков попадает в определённые стандартные темповые зоны.
3. Сильная ненормальность: распределение мультимодальное.

2.5 KDE по остальным признакам

Для признаков:

- `speechiness`
- `acousticness`
- `instrumentalness`
- `liveness`
- `valence`
- `duration_ms`
- `track_popularity`

также были построены KDE-графики (см. Приложение А). Краткие наблюдения:

1. `speechiness`, `instrumentalness`, `liveness` имеют сильно правостороннее распределение (большинство значений около нуля).
2. `valence` — колоколоподобное распределение с небольшими искажениями.
3. `duration_ms` — длинный правый хвост (длинные треки встречаются редко).
4. `track_popularity` — равномерно-пилообразная структура: популярность треков распределена несимметрично.

2.6 Общие выводы по KDE-графикам

1. Большинство признаков обладают умеренной или выраженной асимметрией и не являются нормально распределёнными.
2. Признаки `danceability`, `energy` и `valence` демонстрируют распределения, близкие к одномодальным.
3. Признак `tempo` ярко выраженно мультимодален.
4. Методы KDE хорошо подходят для визуального анализа структуры данных и выявления скрытых особенностей признаков.

3 Анализ данных с помощью boxplot, stripchart, dotchart и cdplot

После изучения сглаженных распределений (KDE) перейдём к более устойчивым к выбросам и асимметрии визуализациям: boxplot и stripchart для всех числовых признаков, а также к групповым графикам dotchart и cdplot для сравнения поджанров плейлистов.

3.1 Boxplot для числовых признаков

Boxplot (ящик с усами) отражает медиану, межквартильный размах и возможные выбросы. Для удобства сравнения все числовые признаки сведены на один график. В целях интерпретации длительность переведена в минуты, а темп представлен в ударах в секунду (BPS).




Figure 6: Boxplot для всех числовых признаков (duration в минутах, tempo в BPS)

Выводы по boxplot:

1. Для большинства признаков заметна асимметрия распределений (особенно у `speechiness`, `instrumentalness`, `liveness`, `acousticness`), что визуально подтверждает ненормальность данных.
2. Признак длительности имеет длинный правый хвост: основная часть треков находится в диапазоне типичных длительностей, а очень длинные треки встречаются редко.

3. У `tempo` наблюдается большой разброс и выбросы, что согласуется с мультимодальностью, выявленной на KDE-графиках.
4. Часть выбросов носит естественный характер для музыкальных данных (например, экстремальные темпы или нетипичная громкость), поэтому их удаление требует осторожности.

3.2 Stripchart для числовых признаков

Stripchart — это облако точек вдоль оси признака с небольшим вертикальным разбросом. Он помогает увидеть плотность наблюдений и возможные кластеры.




Figure 7: Stripchart для числовых признаков

Выводы по stripchart:

1. У ряда признаков значения концентрируются около нуля (`speechiness`, `instrumentalness`, `liveness`), что говорит о сильной правосторонней асимметрии.
2. Для `danceability` и `energy` виден более компактный диапазон значений: эти признаки наиболее «стабильны».
3. Визуально подтверждается неоднородность распределений между признаками, поэтому параметрические тесты нужно применять только после проверки нормальности.

3.3 Нормализованные boxplot (z-score)

Для корректного сравнения признаков независимо от масштаба каждый признак был стандартизирован:

$$z = \frac{x - \bar{x}}{s}.$$

После этого построены boxplot по z-значениям.




Figure 8: Boxplot после стандартизации (z-score)

Выводы по нормализованным boxplot:

1. После стандартизации особенно выделяются тяжёлые хвосты у `tempo`, `loudness` и `track_popularity`.
2. У сильно правоскосях признаков (`speechiness`, `instrumentalness`) асимметрия сохраняется даже после нормализации.

3.4 Dotchart: сравнение танцевальности по поджанрам

Dotchart показывает средние значения `danceability` по поджанрам плейлистов.

Выводы по dotchart:

1. Поджанры отличаются по среднему уровню танцевальности, что отражает жанровую специфику аудиопризнаков.
2. Различия умеренные, но устойчивые — поджанр стоит учитывать как фактор в дальнейшем анализе и моделях.




Figure 9: Dotchart: средняя danceability по поджанрам

3.5 CD-plot аналог: распределение популярности по поджанрам

CD-plot показывает доли треков разной популярности внутри каждого поджанра. Популярность была разбита на квантильные группы.

Выводы по CD-plot:

1. В разных поджанрах доля высокопопулярных треков различается, то есть популярность имеет жанровую зависимость.
2. Это подтверждает, что на популярность влияет не только содержание трека, но и структура плейлистов/поджанров.

3.6 Общий итог по разделу

1. Boxplot и stripchart подтвердили асимметрию и наличие хвостов у большинства признаков.




Figure 10: CD-plot аналог: распределение популярности по поджанрам

2. Dotchart и CD-plot выявили устойчивые различия между поджанрами по `danceability` и `track_popularity`.
3. Следовательно, при дальнейшем анализе важно: (i) чаще опираться на непараметрические методы, (ii) учитывать поджанр как фактор, (iii) трактовать выбросы как естественную часть музыкальных данных.

3.7 Сравнение результатов с реализацией на языке R

Для проверки устойчивости выводов те же визуализации были построены на языке R: `boxplot` и `stripchart` для числовых признаков, а также `dotchart` и `CD-plot` для сравнения жанров/поджанров плейлистов. Графики сохранены в директорию `r_figures/`.

3.7.1 Boxplot и stripchart в R

На рис. 11 и 12 показаны аналоги общих `boxplot` и `stripchart`, построенные в R.

Выводы по графикам на R:




Figure 11: Boxplots для числовых признаков без `duration_ms` (реализация на R)

1. Форма распределений и наличие асимметрии согласуются с Python: правосторонняя скошенность для `speechiness`, `instrumentalness`, `liveness` и тяжёлые хвосты для `tempo`, `track_popularity`.
2. Потенциальные выбросы визуально совпадают по смыслу: в R наблюдаются те же экстремальные значения громкости и темпа.

3.7.2 Нормализованные boxplot (z-score) в R

Короткий вывод: после стандартизации выделяются те же признаки с тяжёлыми хвостами, что и в Python (особенно `tempo`, `loudness`, `track_popularity`).

3.7.3 Dotchart и CD-plot в R

На языке R построены аналогичные групповые графики: dotchart средних значений `danceability` и CD-plot распределения `track_popularity` по жанрам.

Выводы по групповым графикам на R:

1. Упорядочивание жанров по среднему уровню `danceability` совпадает с Python: «танцевальные» жанры остаются сверху.
2. Структура распределений популярности по бидам такая же: есть жанры с большей долей высокопопулярных треков.




Figure 12: Stripchart для числовых признаков без `duration_ms` (реализация на R)

3.7.4 Общий вывод о сравнении Python и R

1. Реализации визуализаций в Python и R дают одинаковую интерпретацию; различия связаны только со стилем построения.
2. Следовательно, выводы об асимметрии признаков, выбросах и жанровых различиях устойчивы и не зависят от языка реализации.




Figure 13: Нормализованные boxplot (z-score), реализация на R

4 Выявление выбросов с точки зрения формальных критериев Граббса и Q-теста Диксона

Критерии Граббса и Q-тест Диксона предназначены для поиска выбросов в одномерной выборке, **при условии нормальности распределения**. Поэтому перед применением этих тестов нужно проверить, насколько соответствующие признаки близки к нормальным.

В качестве реальных примеров из датасета Spotify Songs рассмотрены признаки **tempo** и **loudness**. Далее показано, что оба признака существенно ненормальны, поэтому формальные тесты выбросов на реальных данных неприменимы. Чтобы продемонстрировать корректную работу критериев, они также проверены на синтетической нормальной выборке.

4.1 Проверка нормальности для tempo и loudness (Python)

Сначала рассмотрим форму распределения признаков через гистограммы, KDE и QQ-графики.




Figure 14: Dotchart: средняя danceability по жанрам (реализация на R)




Figure 15: CD-plot аналог: распределение популярности по жанрам (реализация на R)

4.1.1 Признак tempo

На гистограмме видно, что распределение темпа не похоже на нормальное: оно асимметрично и мультимодально. Основная масса значений сосредоточена около ~ 120 BPM, но присутствуют тяжёлые хвосты со стороны низких и высоких темпов. QQ-график подтверждает ненормальность: точки заметно отклоняются от диагонали на концах.

Тесты нормальности (Python) для tempo:

- Shapiro–Wilk: $p = 9.34 \cdot 10^{-29} \ll 0.05$;
- Anderson–Darling: $A^2 = 131.525$, что значительно больше критических значений (даже на уровне 1%: $A_{crit}^2 = 1.092$).

Вывод: нормальность для tempo уверенно отвергается.




Figure 16: Гистограмма и KDE для tempo (Python)




Figure 17: QQ-график для tempo (Python)

4.1.2 Признак loudness

Распределение громкости также явно ненормально: основная масса значений лежит в диапазоне $-5 \dots -10$ dB, присутствует длинный левый хвост (очень тихие треки), а справа наблюдается «естественная граница» около 0 dBFS. QQ-график демонстрирует сильные отклонения от диагонали в хвостах.

Тесты нормальности (Python) для loudness:

- Shapiro–Wilk: $p = 7.28 \cdot 10^{-42} \ll 0.05$;
- Anderson–Darling: $A^2 = 272.769 \gg 1.092$.

Вывод: нормальность для loudness также уверенно отвергается.

Следовательно, на реальных данных Spotify **предпосылка нормальности нарушена**, поэтому критерии Граббса и Диксона **строго говоря, неприменимы** для поиска математических выбросов в этих признаках.




Figure 18: Гистограмма и KDE для loudness (Python)




Figure 19: QQ-график для loudness (Python)

4.2 Проверка нормальности и выбросов в R

Для проверки устойчивости выводов те же процедуры выполнены на языке R.

4.2.1 QQ-графики с огибающими (R)

Оба QQ-графика показывают систематический выход точек за пределы огибающих, что соответствует сильной ненормальности распределений.

4.2.2 Граббс на реальных данных (R)

Вывод по R: в R отмечаются такие же экстремальные значения, что и в Python, но из-за ненормальности они трактуются как потенциальные кандидаты на выбросы, а не как строгие математические выбросы.




Figure 20: QQ-график с огибающей для tempo (R)

4.3 Критерий Граббса

Критерий Граббса используется для проверки, является ли самое экстремальное значение (минимум или максимум) выбросом в нормальной выборке. Статистика имеет вид:

$$G = \frac{|X_i - \bar{X}|}{s},$$

где X_i — проверяемое экстремальное значение, $\bar{X}$ — среднее, s — стандартное отклонение. Если $G > G_{crit}(\alpha, n)$, то значение признаётся выбросом.

На реальных признаках Spotify нормальность нарушена, поэтому тест используется только как демонстрация.

4.4 Q-тест Диксона

Q-тест Диксона предназначен для малых выборок ($3 \leq n \leq 20$). Пусть $x_{(1)} \leq \dots \leq x_{(n)}$ — отсортированная выборка. Тогда при проверке максимального выброса:

$$Q = \frac{x_{(n)} - x_{(n-1)}}{x_{(n)} - x_{(1)}},$$

а при проверке минимального выброса:

$$Q = \frac{x_{(2)} - x_{(1)}}{x_{(n)} - x_{(1)}}.$$

Если $Q > Q_{crit}(\alpha, n)$, то выброс фиксируется.

4.5 Демонстрация корректной работы тестов на синтетической нормали

Чтобы показать работу критериев при выполнении предпосылок, создана нормальная выборка размера $n = 30$ и затем к ней добавлен искусственный выброс.




Figure 21: QQ-график с огибающей для loudness (R)

4.5.1 Результаты Python

Нормальность:

- x_{clean} : Shapiro $p = 0.687$, AD = 0.232 — нормальность не отвергается;
- $x_{\text{with outlier}}$: Shapiro $p = 4.23 \cdot 10^{-4}$ — нормальность нарушена.

Граббс (Python):

- x_{clean} : $G = 1.964 < G_{\text{crit}} = 2.908$ — выброса нет;
- $x_{\text{with outlier}}$: $G = 3.865 > G_{\text{crit}} = 2.908$ — выброс найден.

Диксон (Python):

- x_{clean} : $Q = 0.054 < Q_{\text{crit}} = 0.260$ — выброса нет;
- $x_{\text{with outlier}}$: $Q = 0.495 > Q_{\text{crit}} = 0.260$ — выброс найден.

4.5.2 Результаты R

Нормальность (R):

- $x_{\text{clean_demo}}$: Shapiro $p = 0.1239 > 0.05$ — нормальность не отвергается;
- $x_{\text{out_demo}}$: Shapiro $p = 0.000928 < 0.05$ — нормальность нарушена.

Граббс (R):

- $x_{\text{clean_demo}}$: $p = 0.0575 > 0.05$ — выброса нет;
- $x_{\text{out_demo}}$: $p = 0.0007746 < 0.05$ — выброс найден.




Figure 22: Boxplot `tempo` с потенциальными выбросами (Граббс, R)

Диксон (R):

- $x_{\text{clean_demo}}$: $p = 0.0927 > 0.05$ — выброса нет;
- $x_{\text{out_demo}}$: $p = 0.0562$ и по альтернативе тест фиксирует верхний выброс (итог совпадает по смыслу с Python).

4.6 Итоговые выводы по главе

1. Реальные признаки Spotify `tempo` и `loudness` существенно ненормальны (Shapiro $p \ll 0.05$, AD статистики намного выше критических).
2. Поэтому критерии Граббса и Диксона **формально неприменимы** к реальным данным и могут использоваться только как ориентир на экстремальные значения.
3. На синтетически нормальных данных оба теста (и в Python, и в R) корректно обнаруживают искусственный выброс.
4. Следовательно, методы корректны, но требуют строгого выполнения предпосылки нормальности распределения.




Figure 23: Гистограмма `tempo` с потенциальными выбросами (Граббс, R)

5 Заполнение пропусков: сравнение методов `mean`, `kNN` и `MICE`

Пропуски в данных (NA) неизбежно возникают в реальных наборах данных. Их необходимо корректно обрабатывать, поскольку пропуски могут:

1. искажать статистические выводы и параметры распределений;
2. ухудшать качество моделей машинного обучения;
3. уменьшать объём доступной информации при удалении строк с пропусками.

В рамках эксперимента пропуски были внесены **искусственно** в 10% случайных значений (MCAR – Missing Completely At Random). Далее были протестированы три наиболее распространённых метода:

- среднее значение (**mean imputation**);
- метод ближайших соседей (**kNN**, $k = 5$);
- множественная импутация (**MICE**).

Для оценки качества восстановления использована метрика

$$\text{MSE} = \frac{1}{n} \sum_{i=1}^n (x_i - \hat{x}_i)^2,$$

где x_i — истинное значение, $\hat{x}_i$ — восстановленное значение.

5.1 Распределение признака до и после внесения пропусков

На рис. 30 показано, как искусственные пропуски влияют на форму распределения признака `loudness`.

Пропуски делают распределение менее гладким, что подтверждает необходимость их заполнения.




Figure 24: Boxplot `loudness` с потенциальными выбросами (Граббс, R)

5.2 Сравнение методов импутации на Python

После заполнения пропусков рассчитан MSE для каждого метода:

$$\text{mean} = 2.886192 \times 10^8, \quad \text{kNN} = 2.948544 \times 10^8, \quad \text{MICE} = 2.689531 \times 10^8.$$

Результаты визуализированы на рис. 31.

Выводы по Python:

1. Метод **MICE** показывает наименьшее MSE — он лучше всего восстанавливает «структуру» пропусков.
2. Метод **mean** работает хуже MICE, поскольку сглаживает распределение и уменьшает дисперсию.
3. **kNN** чувствителен к масштабам и локальным выбросам — MSE выше, чем у MICE.

5.3 Сравнение истинных и восстановленных значений

Дополнительно проведено сравнение истинных и восстановленных значений (MICE). На рис. 32 видно, что точки расположены близко к диагонали, значит метод хорошо восстанавливает локальную структуру данных.

5.4 Сравнение методов импутации на языке R

Аналогичный эксперимент проведён в R: искусственно внесены 10% пропусков, и проведено заполнение теми же методами.

Полученные значения MSE:

$$\text{mean} = 3.08833212 \times 10^8, \quad \text{kNN} = 3.22311685 \times 10^8, \quad \text{MICE} = 5.91603752 \times 10^8.$$

Результат визуализирован на рис. 33.

Комментарии по R:




Figure 25: Гистограмма `loudness` с потенциальными выбросами (Граббс, R)




Figure 26: Синтетическая нормальная выборка без выброса (Python)

1. Метод **mean** снова показывает лучшее качество, чем kNN.
2. В отличие от Python, **MICE** дал значительно более высокое MSE.

Причина: в R MICE использует регрессии по умолчанию, которые могут плохо работать при высокой корреляции между признаками или при дисперсионных эффектах.

5.5 Сравнение Python и R

Python: лучшим оказался MICE (самый маленький MSE). **R:** лучшим оказался mean, MICE — худший.

Причины различий:

- разные реализации MICE в sklearn и R (регрессионные модели, параметры);
- различия в обработке факторов и числовых переменных;
- стохастичность процедуры множественной импутации.

5.6 Общие выводы

1. Внесение пропусков (10% MCAR) искажает форму распределения признаков, поэтому импутация обязательна.




Figure 27: Синтетическая нормальная выборка с выбросом (Python)




Figure 28: Синтетическая нормальная выборка без выброса (R)

2. Метод MICE является наиболее точным в Python, тогда как в R он может работать хуже.
3. Методы mean и kNN дают среднее качество, mean — более устойчивый, а kNN — чувствителен к масштабу данных.
4. Сравнение истинных и восстановленных значений показывает, что MICE в Python лучше сохраняет структуру данных.




Figure 29: Синтетическая нормальная выборка с выбросом (R)




Figure 30: Распределение признака до и после внесения 10% пропусков

6 Проверка нормальности: тесты, Q–Q графики с огибающей и гистограммы

В этом разделе нормальность анализируется двумя способами:

1. на синтетических выборках из нормального распределения малого и большого объёмов (для проверки корректности методов);
2. на реальных признаках датасета Spotify Songs (**tempo** и **loudness**).

Для каждого случая строились гистограммы с наложенной нормальной плотностью, а также Q–Q графики с симуляционной огибающей (95%). Дополнительно применялись стандартные тесты нормальности (Shapiro–Wilk, Anderson–Darling и др.), и результаты сравнивались между Python и R.

6.1 Синтетические нормальные выборки

Сгенерированы две выборки:

- **small** объёма $n = 80$ из $N(0, 1)$;
- **moder** объёма $n = 4000$ из $N(1, 2^2)$.




Figure 31: Сравнение методов импутации по MSE (Python, 10% MCAR)

Цель — показать, как ведут себя Q–Q графики и тесты при выполнении предпосылки нормальности.

6.1.1 Результаты на Python

На рис. 34–37 представлены Q–Q графики с огибающей и гистограммы для обеих синтетических выборок.

Интерпретация.

- Для выборки **small** точки Q–Q графика в целом лежат внутри огибающей, допускаются небольшие колебания на хвостах, что естественно для малого объёма. Гистограмма имеет колоколообразный вид и хорошо согласуется с наложенной нормальной плотностью.
- Для выборки **moder** Q–Q график практически совпадает с диагональю, огибающая очень узкая (большой объём сглаживает шум). Гистограмма почти идеально повторяет нормальную плотность.

Таким образом, визуально обе синтетические выборки согласуются с нормальным законом.

6.1.2 Результаты на R и сравнение с Python

На языке R получены те же графики и расчёт тестов нормальности для **small** и **moder**. Табличные результаты тестов:

- **small** ($n = 80$): Shapiro–Wilk $p = 0.9867$, D’Agostino $p = 0.8130$, Jarque–Bera $p = 0.9297$, Cramér–von Mises $p = 0.9589$, Anderson–Darling $A^2 = 0.138$, Lilliefors $p = 0.932$.
- **moder** ($n = 4000$): Shapiro–Wilk $p = 0.5506$, D’Agostino $p = 0.9071$, Jarque–Bera $p = 0.8027$, Cramér–von Mises $p = 0.8825$, Anderson–Darling $A^2 = 0.209$, Lilliefors $p = 0.813$.

Во всех тестах $p\text{-value} > 0.05$, поэтому гипотеза нормальности не отвергается, а визуальные выводы совпадают с Python.




Figure 32: Сравнение истинных и восстановленных значений (MICE)

Вывод по синтетическим данным. Q–Q графики с огибающей и гистограммы на обоих языках подтверждают нормальность сгенерированных выборок; тесты также не отвергают нормальный закон.

6.2 Нормальность реальных признаков Spotify Songs

Далее нормальность проверяется для реальных признаков `tempo` и `loudness` из датасета Spotify Songs. Результаты на Python и R сравниваются между собой.

6.2.1 Python: Q–Q графики и гистограммы

Интерпретация `tempo`. На гистограмме (рис. 39) распределение темпа заметно асимметрично, имеет выраженные хвосты и вероятную многомодальность: основная масса значений около ~ 120 BPM, но присутствует заметная доля медленных треков (примерно 60–90 BPM) и небольшой пик быстрых (выше 150 BPM). Q–Q график (рис. 38) показывает систематическое отклонение точек от диагонали на хвостах, причём множество точек выходит за огибающую. Это типичный признак тяжёлых хвостов и ненормальности.

Интерпретация `loudness`. Гистограмма (рис. 41) односторонне скошена, основная масса значений лежит в диапазоне примерно $[-10, -5]$ dB, присутствует длинный левый хвост (очень тихие записи до ~ -34 dB). Справа распределение ограничено около 0 dB. Q–Q график (рис. 40) также демонстрирует отклонения от диагонали в хвостах, что подтверждает ненормальность.

6.2.2 Python: формальные тесты нормальности

Для обоих признаков вычислены тесты Shapiro–Wilk и Anderson–Darling:

- **`tempo`:** Shapiro–Wilk $p = 9.340 \cdot 10^{-29}$, Anderson–Darling $A^2 = 131.525$ (значительно выше критических значений: 0.576, 0.656, 0.787, 0.918, 1.092).
- **`loudness`:** Shapiro–Wilk $p = 7.280 \cdot 10^{-42}$, Anderson–Darling $A^2 = 272.769$ (также намного выше критических значений).




Figure 33: Сравнение методов импутации по MSE (R, 10% MCAR)

Во всех случаях $p\text{-value} \ll 0.05$, поэтому гипотеза нормальности уверенно отвергается.

6.2.3 R: графики и сравнение

На языке R построены аналогичные Q–Q графики с огибающей и гистограммы (файлы в папке `r_figures/`).

Визуальная картина в R совпадает с Python: `tempo` и `loudness` демонстрируют тяжёлые хвосты и устойчивые отклонения от диагонали на Q–Q графиках, что подтверждает ненормальность распределений. Формальные тесты на R приводят к тем же выводам ($p\text{-value} < 0.05$ для реальных признаков).

6.3 Общий вывод по разделу

1. На синтетических нормальных данных (`small`, `moder`) Q–Q графики с огибающей и гистограммы показывают соответствие нормальному закону, а тесты нормальности на Python и R не отвергают H_0 ($p > 0.05$).
2. На реальных признаках Spotify Songs (`tempo`, `loudness`) визуальные методы и тесты согласованно указывают на ненормальность: $p\text{-value}$ теста Шапиро–Уилка стремится к нулю, статистика Anderson–Darling многократно превышает критические уровни.
3. Следовательно, распределения `tempo` и `loudness` имеют выраженную асимметрию и тяжёлые хвосты, что важно учитывать при дальнейшем анализе и выборе статистических критериев.

7 Одновыборочный критерий Стьюдента

Рассмотрим выборку популярности треков в жанре *pop*. В качестве гипотетического среднего μ_0 примем среднюю популярность всех треков датасета, которая равна

$$\mu_0 = 42.44.$$

Нулевая гипотеза имеет вид

$$H_0 : \mu_{\text{pop}} = \mu_0,$$




Figure 34: Q–Q график с огибающей для synthetic `small` ($n = 80$), Python

а в качестве альтернативных рассматриваются следующие гипотезы:

двусторонняя:	$H_1 : \mu_{\text{pop}} \neq \mu_0,$
односторонняя (greater):	$H_1 : \mu_{\text{pop}} > \mu_0,$
односторонняя (less):	$H_1 : \mu_{\text{pop}} < \mu_0.$

По результатам одновыборочного t-теста на выборке популярности треков жанра *pop* были получены значения

$$t = 13.998, \quad p\text{-value}_{\text{двустор.}} = 1.68 \cdot 10^{-43}.$$

Так как полученное p -значение многократно меньше любых разумных уровней значимости ($\alpha = 0.10, 0.05, 0.01$), нулевая гипотеза H_0 отвергается. Это означает, что средняя популярность треков в жанре *pop* статистически значимо отличается от общего среднего по датасету.

Далее рассмотрим односторонние альтернативы. Для гипотезы

$$H_1 : \mu_{\text{pop}} > \mu_0$$

получено

$$p\text{-value}_{\text{greater}} = 8.39 \cdot 10^{-44},$$

что позволяет уверенно отвергнуть нулевую гипотезу и сделать вывод $\mu_{\text{pop}} > \mu_0$, то есть средняя популярность треков жанра *pop* статистически значимо *выше* средней популярности по всему датасету. Для противоположной альтернативы

$$H_1 : \mu_{\text{pop}} < \mu_0$$

получено

$$p\text{-value}_{\text{less}} = 1.00,$$

что, напротив, полностью противоречит гипотезе о меньшей популярности жанра *pop* по сравнению с общим средним.




Figure 35: Гистограмма с нормальной плотностью для `synthetic small` ($n = 80$), Python

Размер эффекта по Коэну для одновыборочного теста равен

$$d = 0.22,$$

что соответствует малому, но устойчивому эффекту: популярность треков жанра рор выше средней по датасету, однако разница не является очень большой.

Рассчитанная мощность теста при имеющемся объёме выборки составляет

$$\text{power} = 1.00,$$

то есть вероятность ошибки второго рода практически равна нулю. Необходимый размер выборки для достижения мощности 0.8 при уровне значимости $\alpha = 0.05$ равен

$$n_{\text{required}} = 162,$$

что существенно меньше фактического количества наблюдений.

Таким образом, одновыборочный критерий Стьюдента показывает, что средняя популярность треков в жанре рор статистически значимо превышает среднюю популярность всех треков датасета Spotify при любом стандартном уровне значимости.




Figure 36: Q–Q график с огибающей для `synthetic moder` ($n = 4000$), Python

7.1 Двухвыборочный критерий Стьюдента для двух независимых выборок

В данном пункте сравнивается популярность треков в двух независимых группах: жанре *pop* и жанре *rock*. Для каждой группы рассматривается переменная `track_popularity`.

Обозначим через μ_{pop} и μ_{rock} математические ожидания популярности треков в жанрах *pop* и *rock* соответственно. Объёмы выборок и выборочные средние имеют вид:

$$\begin{aligned} n_{\text{pop}} &= 3993, & n_{\text{rock}} &= 3521, \\ \bar{x}_{\text{pop}} &= 47.98, & \bar{x}_{\text{rock}} &= 42.12. \end{aligned}$$

Постановка гипотез

Нулевая гипотеза:

$$H_0 : \mu_{\text{pop}} = \mu_{\text{rock}},$$

то есть средняя популярность треков в жанрах *pop* и *rock* не различается.

Альтернативные гипотезы:

двусторонняя:	$H_1 : \mu_{\text{pop}} \neq \mu_{\text{rock}},$
односторонняя (greater):	$H_1 : \mu_{\text{pop}} > \mu_{\text{rock}},$
односторонняя (less):	$H_1 : \mu_{\text{pop}} < \mu_{\text{rock}}.$

Результаты двухвыборочного t-теста (критерий Уэлча)

Поскольку дисперсии в группах могут отличаться, применяется двухвыборочный критерий Стьюдента для независимых выборок без предположения равенства дисперсий (критерий Уэлча). По результатам расчётов получено:

$$t = 10.260, \quad p\text{-value}_{\text{двустор.}} = 1.55 \cdot 10^{-24}.$$




Figure 37: Гистограмма с нормальной плотностью для `synthetic moder` ($n = 4000$), Python

Значение p -value многократно меньше стандартных уровней значимости $\alpha = 0.10, 0.05, 0.01$, следовательно, нулевая гипотеза

$$H_0 : \mu_{\text{pop}} = \mu_{\text{rock}}$$

отвергается. Это означает, что *средние популярности треков в жанрах pop и rock статистически значимо различаются*.

Односторонние альтернативы

Далее рассмотрим одностороннюю альтернативу

$$H_1 : \mu_{\text{pop}} > \mu_{\text{rock}}.$$

Соответствующее одностороннее p -значение равно

$$p\text{-value}_{\text{greater}} = 7.74 \cdot 10^{-25},$$

что также гораздо меньше любого разумного уровня значимости. Следовательно, мы имеем все основания отвергнуть нулевую гипотезу в пользу альтернативы и заключить, что

$$\mu_{\text{pop}} > \mu_{\text{rock}}.$$

Иными словами, треки жанра *pop* в среднем статистически значимо *более популярны*, чем треки жанра *rock*. Для противоположной альтернативы

$$H_1 : \mu_{\text{pop}} < \mu_{\text{rock}}$$

одностороннее p -значение равно

$$p\text{-value}_{\text{less}} = 1.00,$$

что полностью противоречит гипотезе о меньшей популярности жанра *pop* по сравнению с *rock*.




Figure 38: Q–Q график с огибающей для `tempo`, Python

Размер эффекта и мощность теста

Для количественной оценки величины различий был рассчитан размер эффекта по Коэну:

$$d = 0.24.$$

Такое значение соответствует малому, но устойчивому эффекту: различия в популярности между жанрами *pop* и *rock* присутствуют, но они не являются очень большими по величине. Тем не менее, за счёт большого объёма выборки эти различия выявляются с высокой точностью.




Figure 39: Гистограмма с нормальной плотностью для `tempo`, Python




Figure 40: Q–Q график с огибающей для `loudness`, Python




Figure 41: Гистограмма с нормальной плотностью для loudness, Python




Figure 42: Q-Q график с огибающей для tempo, R




Figure 43: Гистограмма с нормальной плотностью для `tempo`, R




Figure 44: Q-Q график с огибающей для `loudness`, R






Figure 45: Гистограмма с нормальной плотностью для loudness, R



(a) Python: мощность t-теста



(b) R: power-curve

Figure 46: Анализ мощности двухвыборочного t-теста.

Далее была оценена мощность двухвыборочного t-теста при уровне значимости $\alpha = 0.05$ и фактических размерах выборок:

$$\text{power} = 1.00.$$

Это означает, что вероятность ошибки второго рода (не обнаружить существующее различие) практически равна нулю, и полученный результат надёжен.

Кроме того, был вычислен необходимый объём выборки на одну группу для достижения мощности 0.8 при тех же параметрах теста:

$$n_{\text{required}} = 281.$$

Этот объём существенно меньше реальных размеров выборок (3993 и 3521 наблюдений), что ещё раз подтверждает, что имеющихся данных более чем достаточно для уверенного выявления различий.

Итоговый вывод

Проведённый двухвыборочный критерий Стьюдента (в модификации Уэлча) показал, что:

- средние значения популярности треков в жанрах *pop* и *rock* статистически значимо различаются;
- односторонний анализ свидетельствует о том, что $\mu_{\text{pop}} > \mu_{\text{rock}}$, то есть треки жанра *pop* в среднем более популярны, чем треки жанра *rock*;
- размер эффекта $d = 0.24$ указывает на небольшую, но устойчивую разницу между жанрами;
- высокая мощность теста (практически равная 1) и большие объёмы выборок делают сделанные выводы статистически надёжными.

Таким образом, статистический анализ подтверждает, что жанр *pop* в рассматриваемом датасете Spotify обладает более высокой средней популярностью по сравнению с жанром *rock*.

7.2 Критерий Уилкоксона–Манна–Уитни

7.3 Пояснения к критерию Манна–Уитни и тестам на равенство дисперсий

В данном разделе рассмотрим более подробно, какие статистические величины используются в непараметрическом критерии Манна–Уитни и в тестах на равенство дисперсий, а также что именно проверяется в этих тестах.

Критерий Уилкоксона–Манна–Уитни: что означает статистика U

Критерий Манна–Уитни применяется для проверки гипотезы о равенстве *распределений* двух независимых выборок, не предполагая нормальности данных. В отличие от двухвыборочного t -теста, который сравнивает средние, критерий Манна–Уитни сравнивает *ранги* элементов двух выборок.

Пусть

$$X = (x_1, \dots, x_{n_1}), \quad Y = (y_1, \dots, y_{n_2})$$

— выборки популярности треков в жанрах *pop* и *rock* соответственно. Гипотезы формулируются следующим образом:


$$H_0 : F_X = F_Y, \quad H_1 : F_X \neq F_Y \quad (\text{двусторонняя альтернатива}).$$

После объединения двух выборок и ранжирования всех наблюдений вычисляется *статистика Манна–Уитни* U . Она отражает, насколько ранги значений одной выборки систематически превосходят ранги другой. Если распределения одинаковы, то ранги перемешиваются случайным образом и значение U будет близко к своему ожидаемому значению. Сильное отклонение U от ожидания указывает на различие между распределениями.


В нашем исследовании получено:

$$U = 8039489.5, \quad p_{\text{двусторонн.}} = 5.05 \cdot 10^{-27}, \quad p_{\text{greater}} = 2.52 \cdot 10^{-27}.$$

Так как $p \ll 0.01$, нулевая гипотеза отвергается. Распределения популярности в жанрах *pop* и *rock* статистически значимо различаются, причём односторонний тест подтверждает, что треки жанра *pop* имеют более высокие значения популярности.




(a) Python: boxplot pop vs rock




(b) R: boxplot pop vs rock

Figure 47: Сравнение `track_popularity` между жанрами *pop* и *rock*.



(a) Python: гистограммы pop vs rock



(b) R: гистограммы pop vs rock

Figure 48: Форма распределений популярности в pop и rock.

Интерпретация результатов

- Статистика U в критерии Манна–Уитни отражает сравнение *рангов* двух выборок и используется для проверки равенства *распределений*, не предполагая нормальности данных.
- Статистика F в тестах на равенство дисперсий отражает сравнение *разброса* наблюдений и применяется для проверки равенства *дисперсий* двух выборок.
- Эти тесты отвечают на принципиально разные вопросы: критерий Манна–Уитни оценивает сдвиг и форму распределений, тогда как тесты Фишера, Левене и др. определяют, одинаковы ли дисперсии.

Таким образом, статистики U и F являются инструментами для проверки совершенно разных свойств данных, и их совместное использование позволяет получить более полное понимание различий между выборками.

Тесты на равенство дисперсий: что означает статистика F

В следующем анализе рассматривается совершенно другой вопрос: *равны ли дисперсии* популярности в двух жанрах? Здесь проверяется гипотеза:

$$H_0 : \sigma_{\text{pop}}^2 = \sigma_{\text{rock}}^2.$$

Для этого применяются несколько тестов, среди которых тест Фишера, тест Бартлетта, тест Левене и тест Флигнера–Киллина. Их статистики основаны на сравнении выборочных дисперсий.

Центральную роль играет *F-статистика*, обозначаемая буквой F . Она вычисляется как отношение дисперсий (или функций дисперсий) двух выборок. В простейшем случае F-теста Фишера:

$$F = \frac{s_{\text{большой группы}}^2}{s_{\text{меньшей группы}}^2}.$$

Если дисперсии равны, значение F должно быть близким к 1. Чем сильнее F отклоняется в сторону больших значений, тем выше вероятность, что дисперсии различаются. Значимость оценивается с помощью распределения Фишера.

Например, для F-теста Фишера получено:

$$F = 1.047, \quad p = 0.165,$$

что не даёт оснований отвергнуть гипотезу о равенстве дисперсий. Однако при ненормальности данных интерпретация классического F-теста не является надёжной, поэтому используются более робастные тесты (Левене, Флигнера–Киллина).

7.4 Проверка нормальности распределений популярности

Перед применением параметрических критериев сравнения средних и дисперсий необходимо проверить, удовлетворяют ли данные предположению о нормальности. Проверка была выполнена отдельно для выборок популярности треков в жанрах *pop* и *rock*, так как именно эти переменные используются в дальнейших сравнительных тестах.




Figure 49: Проверка нормальности распределения популярности жанра *pop*.

По критерию Шапиро–Уилка были получены:

$$p_{\text{pop}} = 4.3 \cdot 10^{-39}, \quad p_{\text{rock}} = 4.9 \cdot 10^{-42}.$$


Оба значения значительно меньше уровня значимости $\alpha = 0.05$, что означает уверенное отклонение гипотезы о нормальном распределении.

Критерий Андерсона–Дарлинга также показал существенное отклонение от нормальности:


$$A_{\text{pop}}^2 = 85.97, \quad A_{\text{rock}}^2 = 110.77.$$

Обе статистики в десятки раз превышают критические значения, что указывает на крайне сильное нарушение нормальности, выраженную асимметрию и наличие тяжёлых хвостов.


Таким образом, обе выборки популярности (*pop* и *rock*) являются существенно ненормальными. Это обстоятельство необходимо учитывать при выборе статистических тестов: параметрические критерии могут быть менее надёжны, тогда как непараметрические и робастные методы являются предпочтительными.




(a) Python: histogram + KDE (rock)



(b) R: histogram + KDE (rock)



(c) Python: QQ-plot (rock)



(d) R: QQ-plot (rock)

Figure 50: Проверка нормальности распределения популярности жанра *rock*.

7.5 Проверка гипотез об однородности дисперсий

Для исследования вопроса о равенстве дисперсий популярности треков в жанрах *pop* и *rock* были применены четыре критерия, отличающиеся чувствительностью к отклонениям от нормальности:

- **Ф-тест Фишера** — классический параметрический тест, требующий нормальности распределений;
- **Критерий Бартлетта** — параметрический тест, чувствительный к отклонениям от нормальности;
- **Критерий Левене** — робастный тест, устойчивый к ненормальности;
- **Критерий Флигнера–Киллина** — непараметрический тест, полностью независимый от предположения о нормальности.

Пусть σ_{pop}^2 и σ_{rock}^2 обозначают дисперсии популярности в соответствующих жанрах. Нулевая гипотеза:

$$H_0 : \sigma_{\text{pop}}^2 = \sigma_{\text{rock}}^2.$$

Результаты тестов:

Ф-тест

$$F = 1.047, \quad p = 0.165.$$

Гипотеза о равенстве дисперсий не отвергается, однако учитывая ненормальность данных, данный результат следует интерпретировать с осторожностью.

Table 2: Результаты тестов на равенство дисперсий (*pop* vs *rock*).

Тест	Статистика	<i>p</i> -value
Ф-тест Фишера	$F = 1.047$	0.165
Бартлетт	—	0.052
Левене	—	0.861
Флигнер–Киллин	—	0.0014

Критерий Бартлетта

$$p = 0.052.$$

Результат находится на границе значимости: для $\alpha = 0.05$ он незначим, однако становится значимым для $\alpha = 0.10$. Чувствительность теста к ненормальности делает интерпретацию неоднозначной.

Критерий Левене

$$p = 0.861.$$

Данный тест, устойчивый к отклонению от нормальности, не выявил различий между дисперсиями.

Критерий Флигнера–Киллина

$$p = 0.0014.$$

Непараметрический тест показывает наличие статистически значимых различий дисперсий между двумя группами.

Интерпретация

Результаты тестов оказываются противоречивыми: параметрические методы (Фишера, Бартлетта) и робастный тест Левене не выявили значимых различий, в то время как непараметрический критерий Флигнера–Киллина показал существенные различия дисперсий. Такая ситуация объясняется выраженной ненормальностью данных и неоднородностью распределений, особенно в жанре *rock*, где наблюдаются тяжёлые хвосты и большой разброс.


В условиях сильного отклонения от нормальности наиболее надёжными являются критерий Левене и непараметрический тест Флигнера–Киллина. Их результаты и следует использовать при выводах о равенстве дисперсий. Это также оправдывает применение в двухвыборочном *t*-тесте модификации Уэлча (`equal_var = False`), которая не требует предположения о равенстве дисперсий выборок.

//короче тут переделать потому что картинки берутся с другой папки фигур2 а они находятся в фигур а для 5 и 6 в фигур 2


8 Корреляционный анализ

Целью данного раздела является исследование взаимосвязей между числовыми аудиопризнаками треков из датасета Spotify. Для этого были рассчитаны коэффициенты корреляции Пирсона (линейная связь), Спирмена и Кендалла (ранговые меры монотонной зависимости). В анализ включены следующие признаки:

danceability, energy, loudness, speechiness, acousticness, instrumentalness, liveness, valence



(a) Python: violin plot разброса



(b) R: violin plot разброса

Figure 51: Визуальное сравнение дисперсий популярности в pop и rock.

Во всех случаях проверялась нулевая гипотеза

$$H_0 : \rho = 0,$$

где ρ обозначает соответствующий коэффициент корреляции (Пирсона, Спирмена или Кендалла), против двусторонней альтернативы


$$H_1 : \rho \neq 0.$$

8.1 Коэффициент корреляции Пирсона


Коэффициент корреляции Пирсона измеряет тесноту *линейной* связи между двумя количественными переменными и принимает значения в интервале $[-1; 1]$. Значения $|\rho|$, близкие к 1, соответствуют сильной линейной зависимости, а значения, близкие к 0, указывают на отсутствие линейной связи.

На языке Python корреляционная матрица Пирсона была получена функцией `DataFrame.corr(method="pearson")`. Матрица показывает, что:

- наибольшая положительная корреляция наблюдается между **energy** и **loudness**: коэффициент Пирсона составляет примерно $r \approx 0.67$. Это означает, что чем выше “энергичность” трека, тем он, как правило, громче;
- заметная отрицательная корреляция обнаружена между **energy** и **acousticness** ($r \approx -0.55$): более энергичные треки обычно менее “акустические”;



(a) Python: Pearson heatmap



(b) R: Pearson heatmap

Figure 52: Корреляционная матрица Пирсона для аудиопризнаков.


- признаки **danceability** и **valence** демонстрируют умеренную положительную связь ($r \approx 0.34$): более “танцевальные” треки, как правило, воспринимаются как более “позитивные” по настроению;
- для остальных пар признаков значения коэффициентов Пирсона по модулю, как правило, существенно меньше 0.5, что указывает на слабые либо отсутствующие линейные зависимости.

Для пары **energy**–**loudness** дополнительно был рассчитан коэффициент Пирсона с p -значением:


$$r = 0.67, \quad p \ll 0.01.$$

Чрезвычайно малое p -значение позволяет отвергнуть гипотезу $H_0 : r = 0$, то есть линейная связь между **energy** и **loudness** является статистически значимой.

Для наглядности была построена диаграмма рассеяния **energy** против **loudness** с наложенной линией линейной регрессии. Точки облака расположены вдоль восходящей прямой, что визуально подтверждает положительную линейную зависимость и хорошо согласуется с полученным значением коэффициента Пирсона.



(a) Python: energy vs loudness



(b) R: energy vs loudness

Figure 53: Диаграмма рассеяния **energy** и **loudness** с линией регрессии.

8.2 Коэффициент корреляции Спирмена

Коэффициент корреляции Спирмена является ранговой мерой монотонной связи между двумя переменными. Для вычисления используются не исходные значения, а их ранги. Такой подход делает коэффициент Спирмена менее чувствительным к выбросам и отклонениям от нормальности.

Для пары признаков `energy` и `loudness` коэффициент Спирмена был вычислен с помощью функции `spearmanr` из библиотеки `scipy.stats`:

$$\rho_S \approx 0.65, \quad p \ll 0.01.$$

Полученное значение говорит о сильной и статистически значимой *монотонной* связи: при увеличении `energy` значение `loudness` также, как правило, увеличивается. Близость значений коэффициентов Пирсона и Спирмена указывает на то, что зависимость между переменными носит в основном линейный характер и не искажается единичными выбросами.

Аналогично можно рассматривать другие пары признаков. В большинстве случаев коэффициенты Спирмена по модулю остаются умеренными или малыми, что говорит о слабых монотонных связях между остальными аудиопризнаками.

8.3 Коэффициент корреляции Кендалла


Коэффициент корреляции Кендалла τ также является ранговой мерой монотонной связи, основанной на подсчёте числа согласованных и несогласованных пар наблюдений. Он особенно устойчив при наличии выбросов и нелинейных зависимостей и принимает значения из диапазона $[-1; 1]$.

Для пары `energy` и `loudness` коэффициент Кендалла вычислялся с помощью функции `kendalltau`:


$$\tau \approx 0.47, \quad p \ll 0.01.$$

Значение τ около 0.5 говорит о достаточно сильной и устойчивой положительной монотонной связи между признаками. Малое p -значение позволяет отвергнуть гипотезу об отсутствии зависимости. При сравнении с коэффициентами Пирсона и Спирмена видно, что все три меры единообразно указывают на тесную связь между `energy` и `loudness`.

Кроме того, для всех аудиопризнаков была построена корреляционная матрица Кендалла и визуализирована в виде тепловой карты. Структура зависимостей оказалась схожей с матрицей Пирсона: наиболее заметные связи наблюдаются между `energy` и `loudness` (положительная), а также между `energy` и `acousticness` (отрицательная). Для других пар коэффициенты Кендалла по модулю невелики, что соответствует слабым монотонным связям.



(a) Python: Spearman heatmap




(b) R: Spearman heatmap

Figure 54: Корреляционная матрица Спирмена для аудиопризнаков.


8.4 Сводные выводы по корреляционному анализу

Проведённый корреляционный анализ показывает, что:

- во всех трёх подходах (Пирсон, Спирмен, Кендалл) устойчиво выявляется сильная положительная связь между **energy** и **loudness**. Это отражает естественный факт: более энергичные треки, как правило, звучат громче;
- наблюдается умеренная отрицательная зависимость между **energy** и **acousticness**: “живые” акустические записи чаще менее энергичны;
- признаки **danceability** и **valence** демонстрируют умеренную положительную связь, что можно интерпретировать как связь между “танцевальностью” трека и его субъективной “позитивностью”;
- для большинства остальных пар аудиопризнаков коэффициенты корреляции невелики по модулю, что говорит об относительной независимости этих характеристик и подтверждает, что они описывают разные аспекты звучания треков.



(a) Python: Kendall heatmap



(b) R: Kendall heatmap

Figure 55: Корреляционная матрица Кендалла для аудиопризнаков.

Таким образом, корреляционный анализ позволяет выделить несколько ключевых пар взаимосвязанных аудиопризнаков, при этом большинство признаков остаются умеренно или слабо коррелированными, что делает их полезными для дальнейшего моделирования и анализа.

9 Тесты для категориальных данных: χ^2 , точный тест Фишера, критерий Кохрана–Мантеля–Хензеля (СМН)

В данном разделе исследуется взаимосвязь между категориальными переменными: `playlist_genre`, `mode` (0 — минор, 1 — мажор) и `language` (английский / неанглийский). Анализ выполнен в Python и дублирован в R. Все статистики и p -значения совпали до округления, что подтверждает корректность расчётов и воспроизводимость результатов.

9.1 1. Таблицы сопряжённости

В таблице ниже приведено наблюдаемое распределение ладов по жанрам:

Table 3: Наблюдаемые частоты: “жанр $\times$ лад”

Жанр	Минор (0)	Мажор (1)
edm	1009	1036
latin	948	1230
pop	1583	2410
r&b	1579	1747
rap	1582	1809
rock	1040	2481

Аналогичная таблица была построена для “mode $\times$ English” и отдельно для каждого жанра (для СМН-теста).

9.2 2. Критерий χ^2 для независимости

(a) Жанр $\times$ Лад

Результаты Python и R:

$$\chi^2 = 352.07, \quad p = 6.28 \cdot 10^{-74}, \quad df = 5.$$

Ожидаемые частоты:

$$\text{Expected}_{\text{genre} \times \text{mode}} = \begin{pmatrix} 857.83 & 1187.17 \\ 913.62 & 1264.38 \\ 1674.97 & 2318.03 \\ 1395.18 & 1930.82 \\ 1422.44 & 1968.56 \\ 1476.97 & 2044.03 \end{pmatrix}$$

Такое сильное расхождение между наблюдаемыми и ожидаемыми частотами объясняет большое значение χ^2 . Нулевая гипотеза независимости отвергается:

Лад трека статистически зависит от жанра.

(b) Лад $\times$ Английский язык

$$\chi^2 = 45.82, \quad p = 1.30 \cdot 10^{-11}, \quad df = 1.$$

Ожидаемые частоты:

$$\text{Expected}_{\text{mode} \times \text{English}} = \begin{pmatrix} 1278.98 & 6462.02 \\ 1770.02 & 8942.98 \end{pmatrix}$$

Гипотеза независимости также отвергается: в англоязычных треках мажор встречается чаще.

9.3 3. Точный тест Фишера (таблица 2×2)

Для “mode $\times$ English”:

$$\widehat{OR} = 1.310, \quad p = 1.44 \cdot 10^{-11}.$$

Так как $p \ll 0.01$, связь статистически значима. $\widehat{OR} > 1$ означает, что англоязычные треки имеют мажорный лад чаще. R дал тот же OR и то же p -значение.

9.4 4. Критерий Кохрана–Мантеля–Хензеля (СМН)

Для каждого жанра строилась отдельная таблица 2×2 “mode $\times$ English”, после чего вычислялась общая стратифицированная статистика.

$$\chi^2_{\text{СМН}} = 20.34, \quad p = 6.47 \cdot 10^{-6}, \quad \widehat{OR}_{\text{common}} = 1.23.$$


Даже после учёта жанра зависимость сохраняется:

Связь между mode и language остаётся значимой после стратификации.


9.5 5. Тест МакНемара

Тест МакНемара требует парных наблюдений (“до/после”, измерения у одного объекта). В Spotify-датасете таких пар нет: каждый трек независим. Поэтому тест неприменим.


9.6 6. Визуализация категориальных зависимостей



(a) Python: доля мажора по жанрам




(b) Python: доля минора по жанрам




(c) Python: доля англ. треков по mode


Figure 56: Категориальные распределения (Python).



(a) R: доля мажора по жанрам



(b) R: доля минора по жанрам



(c) R: доля англ. треков по mode

Figure 57: Категориальные распределения (R).

Графики подтверждают выводы тестов: в rock и pop доля мажора выше, чем в других жанрах, а англоязычные треки заметно чаще встречаются в мажоре.

9.7 7. Общий вывод по разделу

Проведённый анализ категориальных данных показал устойчивые статистические зависимости между рассматриваемыми признаками:

- χ^2 -тест выявил сильную связь между жанром и ладом трека: $p \approx 6.28 \cdot 10^{-74} \ll 0.01$, следовательно, распределение мажора/минора существенно различается по жанрам.
- χ^2 -тест и точный тест Фишера подтвердили зависимость между ладом и языком: англоязычные треки несколько чаще записаны в мажоре ($OR \approx 1.31$, $p \approx 10^{-11}$).
- СМН-тест показал, что зависимость “mode $\times$ language” сохраняется даже после контроля жанра ($p \approx 6.47 \cdot 10^{-6}$), то есть эффект не является побочным следствием жанровых различий.
- Тест МакНемара неприменим, так как в данных отсутствуют парные наблюдения.
- Результаты R полностью совпали с Python, а визуализации обеих сред подтверждают одни и те же закономерности.

Таким образом, лад трека зависит и от жанра, и от языка, причём эти связи устойчивы и статистически значимы.

10 Проверка мультиколлинеарности

Целью данного этапа является выявление линейной зависимости между объясняющими переменными, так как высокая мультиколлинеарность делает регрессионные модели нестабильными, увеличивает дисперсию оценок коэффициентов и затрудняет интерпретацию результатов. Для диагностики были использованы два основных инструмента: корреляционная матрица и фактор инфляции дисперсии (VIF).

10.1 Корреляционная матрица




Figure 58: Python: корреляционная матрица признаков для диагностики мультиколлинеарности.

Корреляционная матрица позволяет выявить линейные связи между признаками. В полученной матрице наиболее выраженная корреляция наблюдается между переменными `energy` и `loudness`:

$$r_{\text{energy}, \text{loudness}} \approx 0.67.$$

Это ожидаемый результат, поскольку высокая энергия трека зачастую сопровождается высокой громкостью. Кроме того, заметна умеренная отрицательная корреляция между `energy` и `acousticness`

$$r_{\text{energy}, \text{acousticness}} \approx -0.55,$$

что отражает то, что “энергичные” треки, как правило, менее акустические.

Анализ корреляционной матрицы позволяет не только выявить статистические зависимости, но и понять музыкальную природу признаков.

- **Сильная положительная корреляция между energy и loudness** ($r \approx 0.67$) объяснима тем, что более “энергичные” треки почти всегда звучат громче. Эти два признака фактически описывают схожие аспекты динамики и насыщенности звучания, что подтверждается также их высокими значениями VIF.
- **energy отрицательно связана с acousticness** ($r \approx -0.55$), что означает, что натуральные, акустические записи обычно имеют меньшую энергию. Треки с высокой энергетикой чаще построены на электронном продакшене, синтезаторах и плотных ударных, что делает их менее “акустическими”.
- **Умеренная связь между danceability и valence** ($r \approx 0.34$) говорит о том, что более “танцевальные” треки часто имеют более позитивное эмоциональное окрашивание. Это соответствует музыкальным тенденциям: танцевальная музыка часто создаётся в мажорных тональностях и вызывает положительные эмоции.
- **Слабые корреляции большинства остальных признаков** указывают на то, что такие характеристики, как speechiness, liveness, instrumentality, связаны с уникальными аспектами звучания и не имеют выраженных линейных зависимостей с другими параметрами. Например, speechiness зависит от присутствия вокала и речитативных элементов, а instrumentality описывает степень инструментальности композиции и не обязана коррелировать с “энергичностью” или “танцевальностью”.

Таким образом, корреляционный анализ показывает, что музыкальные признаки группируются по смыслу: одни описывают динамику трека (energy, loudness, tempo), другие — эмоциональную окраску (valence, danceability), третьи — структуру и тип записи (acousticness, instrumentality, speechiness). Эти взаимосвязи объясняют, почему некоторые признаки демонстрируют высокую мультиколлинеарность, и подсказывают, какие из них могут быть избыточными в регрессионных моделях.

10.2 Фактор инфляции дисперсии (VIF)

Table 4: Корреляционная матрица числовых признаков (Пирсон).

	danceability	energy	loudness	speechiness	acousticness	instrumentality	liveness	valence	tempo	duration_ms
danceability	1.00	-0.09	0.02	0.20	-0.03	-0.05	-0.11	0.34	-0.20	-0.13
energy	-0.09	1.00	0.67	-0.01	-0.55	0.04	0.16	0.21	0.14	-0.02
loudness	0.02	0.67	1.00	0.03	-0.37	-0.10	0.07	0.05	0.08	-0.16
speechiness	0.20	-0.01	0.03	1.00	-0.00	-0.11	0.06	0.04	0.03	-0.09
acousticness	-0.03	-0.55	-0.37	-0.00	1.00	-0.02	-0.07	-0.07	-0.10	-0.05
instrumentality	-0.05	0.04	-0.10	-0.11	-0.02	1.00	-0.00	-0.10	0.03	0.08
liveness	-0.11	0.16	0.07	0.06	-0.07	-0.00	1.00	-0.01	0.02	0.03
valence	0.34	0.21	0.05	0.04	-0.07	-0.10	-0.01	1.00	-0.02	-0.05
tempo	-0.20	0.14	0.08	0.03	-0.10	0.03	0.02	-0.02	1.00	-0.01
duration_ms	-0.13	-0.02	-0.16	-0.09	-0.05	0.08	0.03	-0.05	-0.01	1.00

Для каждого признака был вычислен показатель VIF. Значения

$$VIF > 5$$

традиционно интерпретируются как признак потенциальной мультиколлинеарности, а значения выше 10 — как серьёзная проблема. Полученные результаты:

$$\begin{aligned}
 \text{energy} : VIF &\approx 22.4, & \text{loudness} : VIF &\approx 9.24, \\
 \text{danceability} : VIF &\approx 17.25, & \text{tempo} : VIF &\approx 17.60, \\
 \text{duration_ms} : VIF &\approx 16.40.
 \end{aligned}$$

- **Высокие VIF у признаков `energy`, `loudness`, `danceability`, `tempo`, `duration_ms`** отражают то, что эти характеристики могут быть производными или взаимосвязанными аспектами общей структуры трека. Например, более быстрый темп нередко встречается в жанрах с высокой энергией, а длительность трека может быть согласована с его энергетической динамикой.
- В то же время признаки `speechiness`, `acousticness`, `instrumentalness`, `liveness`, `valence` имеют умеренные значения VIF (в интервале 1.1–7.7), что не вызывает серьёзных опасений относительно мультиколлинеарности.

Table 5: Факторы инфляции дисперсии (VIF) для аудиопризнаков.

Признак	VIF
danceability	17.25
energy	22.42
loudness	9.24
speechiness	2.24
acousticness	2.07
instrumentalness	1.15
liveness	2.63
valence	7.76
tempo	17.60
duration_ms	16.40

10.3 Выводы

1. Корреляционная матрица показала наличие значимой линейной связи между отдельными парами признаков (в первую очередь между `energy` и `loudness`), тогда как большинство остальных корреляций остаются умеренными.
2. Анализ факторов инфляции дисперсии выявил несколько переменных с высокими значениями VIF (`energy`, `danceability`, `tempo`, `duration_ms`, `loudness`), что может свидетельствовать о сильной линейной зависимости между частями набора признаков.
3. Наличие высоких VIF говорит о потенциальных проблемах при построении регрессионных моделей: оценки коэффициентов могут быть нестабильными и чувствительными к малейшим изменениям данных.
4. Для уменьшения мультиколлинеарности в дальнейшем анализе можно рассмотреть удаление или трансформацию некоторых признаков, объединение связанных признаков в один (например, через PCA), либо применение регуляризации (Ridge, Lasso).

Таким образом, мультиколлинеарность в данных присутствует, но затрагивает не все признаки. Наиболее проблемные переменные следует учитывать при построении регрессионных моделей и выборе методов анализа.

11 Дисперсионный анализ (ANOVA)

Дисперсионный анализ (ANOVA) позволяет определить, отличаются ли средние значения числовой переменной в различных группах, заданных категориальными факторами. В качестве зависимой переменной используется `track_popularity`, а в качестве факторов — жанр плейлиста (`playlist_genre`) и лад музыкального трека (`mode`: 0 — минор, 1 — мажор).

11.1 Предварительная проверка предположений ANOVA

Перед применением ANOVA необходимо проверить три ключевых предположения:

1. **Независимость наблюдений.** Каждая строка датасета соответствует отдельному треку, повторов не наблюдается, поэтому независимость считается выполненной.
2. **Нормальность распределения.** При больших размерах выборок (по 1500–2500 наблюдений в группе) ANOVA является робастным к отклонениям от нормальности. Графический анализ (boxplot) не выявил серьёзных проблем, поэтому условие считаем приближённо выполненным.
3. **Гомогенность дисперсий.** Проверяется с помощью теста Левене.

Проверка гомогенности дисперсий

Для переменной `track_popularity` между жанрами был применён тест Левене:

$$\text{Levene's test: } F = 5.53, \quad p = 4.30 \cdot 10^{-5}.$$

Так как $p < 0.05$, нулевая гипотеза о равенстве дисперсий отвергается. Это означает, что дисперсии популярности треков между жанрами различаются, и формально предположение гомогенности нарушено.

Однако ввиду очень больших размеров выборок ANOVA считается достаточно робастным к умеренным нарушениям этого предположения. Следовательно, применение ANOVA остаётся корректным, но результаты необходимо интерпретировать с осторожностью.

Графики boxplot подтверждают результаты теста Левене: некоторые жанры (*pop*, *latin*, *rap*) имеют гораздо более широкий разброс популярности по сравнению с *edm*, *r&b* и *rock*.

11.2 Однофакторный ANOVA

Для начала был проведён однофакторный ANOVA с фактором `playlist_genre`. Нулевая гипотеза:

$$H_0 : \mu_{\text{rock}} = \mu_{\text{r\&b}} = \mu_{\text{pop}} = \mu_{\text{edm}} = \mu_{\text{latin}} = \mu_{\text{rap}}.$$

Результат анализа:

$$F = 116.58, \quad p < 10^{-10}.$$

Table 6: Однофакторный ANOVA по жанрам

Источник	sum_sq	df	F	PR(>F)
C(playlist_genre)	$3.43 \cdot 10^5$	5	116.58	$< 10^{-10}$
Residual	$1.08 \cdot 10^7$	18448		




Figure 59: Популяриность треков по жанрам (Python и R совпадают).

Так как $p \ll 0.01$, нулевая гипотеза отвергается. Средняя популярность песен **значимо отличается между жанрами**.

График boxplot подтверждает этот вывод: жанры *pop*, *latin* и *rap* имеют более высокие медианные значения популярности, тогда как *rock*, *r&b* и *edm* демонстрируют более низкие уровни популярности.

11.3 Двухфакторный ANOVA

Далее был проведён двухфакторный ANOVA с факторами `playlist_genre` и `mode`, а также их взаимодействием.

Table 7: Двухфакторный ANOVA: жанр, лад и их взаимодействие

Источник	sum_sq	df	F	PR(>F)
C(playlist_genre)	$3.41 \cdot 10^5$	5	116.23	$< 10^{-10}$
C(mode)	24.83	1	0.042	0.837
C(playlist_genre):C(mode)	$1.21 \cdot 10^4$	5	4.117	0.001
Residual	$1.08 \cdot 10^7$	18442		

Нулевые гипотезы:

$H_0^{(\text{genre})}$: средние равны для всех жанров;


$H_0^{(\text{mode})}$: $\mu_{\text{major}} = \mu_{\text{minor}}$;

$H_0^{(\text{interaction})}$: взаимодействие отсутствует.


Результаты:

$$F_{\text{genre}} = 116.23, \quad p < 10^{-10};$$

$$F_{\text{mode}} = 0.042, \quad p = 0.84;$$



(a) Python: interaction plot



(b) R: interaction plot

Figure 60: Взаимодействие жанра и лада (Python и R совпадают).

$$F_{\text{genre:mode}} = 4.117, \quad p = 0.001.$$

Интерпретация:

- фактор **genre** оказывает сильное влияние на популярность ($p \ll 0.01$);
- фактор **mode** сам по себе **не влияет** на популярность ($p > 0.05$);
- взаимодействие факторов **значимо** ($p \approx 0.001$).

График средних значений показывает, что влияние лада на популярность зависит от жанра:

- в *r&b* мажорные треки заметно популярнее минорных;
- в *pop* различия между ладами минимальны;
- в некоторых жанрах линии пересекаются — это указывает на существенное взаимодействие факторов.

Таким образом, влияние лада проявляется только в сочетании с жанром.

11.4 Выводы

1. Жанр музыкального трека статистически значимо влияет на его популярность.
2. Сам по себе лад (мажор/минор) не оказывает значимого эффекта.
3. Однако взаимодействие `genre × mode` значимо: влияние лада зависит от жанра.
4. Графические методы (boxplot и interaction plot) подтверждают выводы ANOVA.
5. Несмотря на нарушение гомогенности дисперсий, большие размеры выборок позволяют корректно использовать ANOVA, интерпретируя результаты с осторожностью.

Таким образом, ANOVA показывает, что популярность треков определяется прежде всего жанром, а эффект лада появляется только во взаимодействии с жанровой принадлежностью.

12 Регрессионный анализ

13 Регрессионный анализ

В данном разделе была построена и проанализирована регрессионная модель, предсказывающая популярность трека (`track_popularity`) на основе аудиопризнаков: `danceability`, `energy`, `loudness`, `valence` и `duration_ms`. Качество моделей оценивалось по метрикам R^2 , MSE, RMSE и MAE, а также проводился анализ остатков. Анализ выполнен в Python и дублирован в R; графики и численные результаты согласуются.

13.1 1. Линейная регрессия (baseline)

Модель линейной регрессии обучалась на стандартизированных данных. Полученные метрики:


$$R_{\text{train}}^2 = 0.043, \quad R_{\text{test}}^2 = 0.032, \\ \text{MSE}_{\text{test}} = 580.26, \quad \text{RMSE}_{\text{test}} = 24.09, \quad \text{MAE}_{\text{test}} = 20.07.$$

Таким образом, линейная модель объясняет лишь около 3% дисперсии популярности, то есть аудиопризнаки почти не позволяют предсказывать `track_popularity` в рамках простой линейной зависимости.


1.1 График «предсказанное vs фактическое»

Из графика видно, что предсказания концентрируются в узком диапазоне примерно 35–55 и почти не реагируют на реальные экстремальные значения, что типично для модели с низким R^2 .

1.2 Анализ остатков



(a) Python: pred vs true (test)



(b) R: pred vs true (test)

Figure 61: Сравнение предсказаний линейной модели с фактическими значениями.

По диаграмме «предсказанное vs остатки» наблюдается веерообразная структура и выбросы, что говорит о нарушении гомоскедастичности и наличии неучтённых зависимостей. QQ-plot и гистограмма показывают тяжёлые хвосты и асимметрию остатков, то есть нормальность ошибок не выполняется.

13.2 2. Попытка убрать мультиколлинеарность (VIF)

Дополнительно была проверена мультиколлинеарность признаков через фактор инфляции дисперсий (VIF). Начальные значения VIF:

```
energy : 2.09,  loudness : 2.00,  valence : 1.25,  danceability : 1.22,  duration_ms : 1.06.
```


Все значения меньше порога 5, поэтому признаки **не удалялись** (список удалённых: пустой). Окончательные VIF совпали с начальными.




(a) Python: предсказанное vs остатки




(b) R: предсказанное vs остатки




(c) Python: QQ-plot остатков



(d) R: QQ-plot остатков



(e) Python: гистограмма остатков



(f) R: гистограмма остатков

Figure 62: Диагностика остатков линейной модели (test).




Figure 63: VIF до и после проверки мультиколлинеарности (Python).

После «VIF-очистки» модель фактически не изменилась, поэтому метрики остались прежними:

Table 8: Сравнение baseline и модели после VIF-проверки

Модель	R^2_{train}	R^2_{test}	$\text{RMSE}_{\text{test}}$	MAE_{test}
base	0.0433	0.0317	24.09	20.07
after_vif	0.0433	0.0317	24.09	20.07

Вывод из VIF-этапа: даже после проверки мультиколлинеарности улучшения нет, поскольку проблема модели связана не со взаимной зависимостью признаков, а со слабой связью аудиопризнаков с популярностью.


13.3 3. Полиномиальная регрессия

Для признака `danceability` была построена квадратичная модель:


$$\hat{y} = ax^2 + bx + c,$$

$$a = 19.28, \quad b = -13.47, \quad c = 42.68, \quad R^2_{\text{poly}} = 0.004.$$

Качество почти не улучшилось относительно baseline, что подтверждает отсутствие выраженной нелинейной связи между танцевальностью трека и его популярностью.




(a) Python: R^2 base vs after VIF



(b) R: R^2 base vs after VIF




(c) Python: RMSE/MAE base vs after VIF



(d) R: RMSE/MAE base vs after VIF

Figure 64: Сравнение качества baseline и модели после VIF (Python и R совпадают).



(а) Полиномиальная аппроксимация зависимости popularity от danceability

Figure 65: Полиномиальная регрессия 2-й степени.

13.4 4. Причины низкого качества моделей

Низкий R^2 связан со свойствами данных:

- `track_popularity` слабо коррелирует с аудиопризнаками (по модулю $|r| < 0.3$);
- популярность определяется внешними факторами (маркетинг, известность исполнителя, продвижение, тренды и т.д.), которых в датасете нет;
- возможные зависимости пороговые/нелинейные и зависят от жанра, а базовые модели их не улавливают.

13.5 Итоговые выводы

1. Baseline линейная модель имеет крайне низкое качество: $R_{\text{test}}^2 \approx 0.03$.
2. Диагностика остатков показывает нарушения предпосылок линейной регрессии (ненормальность и гетероскедастичность).
3. Проверка мультиколлинеарности через VIF не привела к удалению признаков (все $\text{VIF} < 5$), поэтому качество модели не изменилось.
4. Полиномиальная регрессия также не улучшила предсказание ($R_{\text{poly}}^2 \approx 0.004$).
5. Для серьёзного роста качества нужны дополнительные признаки, описывающие социальные/маркетинговые факторы популярности.

Таким образом, популярность треков невозможно надёжно предсказывать только по аудиопризнакам в рамках простых регрессионных моделей.

Заключение

В ходе выполнения практикума был проведён комплексный статистический анализ аудиопризнаков треков из датасета Spotify на языках Python и R. Исследование включало проверки нормальности, сравнение средних с использованием параметрических и непараметрических критериев, анализ дисперсий, категориальные тесты, корреляционный анализ, диагностику мультиколлинеарности и построение регрессионных моделей.

Основные результаты можно сформулировать следующим образом:

- популярность треков существенно различается между жанрами; жанр является сильным фактором, в то время как лад сам по себе значимого влияния не оказывает;
- непараметрические и робастные методы подтвердили ненормальность данных и неоднородность дисперсий, что было учтено при выборе статистических тестов;
- связи между аудиопризнаками оказались преимущественно слабыми или умеренными; наиболее выраженная зависимость наблюдается между **energy** и **loudness**;
- проверка мультиколлинеарности выявила группы коррелирующих признаков, однако удаление переменных по VIF не улучшило качество моделей;
- линейные и полиномиальные регрессионные модели показали крайне низкую предсказательную способность ($R^2 < 0.05$), что указывает на слабую связь аудиопризнаков с популярностью;
- результаты, полученные в Python и R, полностью совпадают, что подтверждает корректность реализации методов и воспроизводимость анализа.

Таким образом, популярность треков в рассматриваемом датасете определяется главным образом жанровой принадлежностью и внешними факторами, не представленными в данных. Аудиопризнаки дают лишь ограниченную информацию и не позволяют построить точные предсказательные модели без расширения набора доступных переменных.

А Приложение А. KDE-графики остальных числовых признаков

В этом приложении приведены KDE-графики для числовых признаков, не рассмотренных подробно в основном тексте.




Figure 66: KDE для признака `speechiness`




Figure 67: KDE для признака `acousticness`




Figure 68: KDE для признака `instrumentality`




Figure 69: KDE для признака `liveness`




Figure 70: KDE для признака `valence`




Figure 71: KDE для признака `duration_ms`




Figure 72: KDE для признака `track_popularity`